

# Análisis de regresión

26 de agosto  
(semana 3)

# Plan de trabajo

1. Inferencia sobre los coeficientes de regresión
2. Predicción en la regresión lineal simple

## Nota:

- No olviden aceptar la invitación al CLASSROOM y revisar acceso al DRIVE y MOODLE (<https://micampus.unal.edu.co/>)
- La primera entrega del trabajo final será para el domingo 4 de septiembre por CLASSROOM.
  - Llenen la lista que les compartí con los integrantes.
  - Si van a recoger sus datos, NO empiecen hasta que yo les dé el aval.
  - En el DRIVE, videos de repaso de estadística descriptiva.
- En la semana del 29 de agosto al 2 de septiembre no habrá clase. Usen ese tiempo para la 1era entrega y el taller 1.
- Impriman por favor material módulo 2 **para la próxima clase.**

# Regresión lineal simple



$$\left\{ \begin{array}{l} Y_k = \mu_k + \varepsilon_k \\ \mu_k = \beta_0 + \beta_1 x_k \\ \varepsilon_k \text{ iid} \end{array} \right.$$

$$\text{Var}(\varepsilon_k) = \sigma^2 \quad \forall k$$

$$E(\varepsilon_k) = 0 \quad \forall k$$

# Estimación de los coeficientes de regresión

❖ **Parámetros:**  $\beta_0$  : intercepto,  $\beta_1$  : pendiente

**Método de mínimos cuadrados ordinarios:** Suponga que se tiene el siguiente modelo:

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i; \quad 1 \leq i \leq n$$

Donde:

1.  $E(\varepsilon_i) = 0 \quad \forall i$
2.  $Var(\varepsilon_i) = \sigma^2 \quad \forall i$
3.  $Cov(\varepsilon_i, \varepsilon_j) = 0 \quad \forall i \neq j$

La estimación de mínimos cuadrados (dados los datos) es:

$$(\hat{\beta}_0, \hat{\beta}_1) = \arg \min_{\beta_0, \beta_1} Q(\beta_0, \beta_1) = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$$

# Solución del problema de minimización (I)

## 1. Puntos críticos.

$$\left\{ \frac{\partial Q}{\partial \beta_0}(\hat{\beta}_0, \hat{\beta}_1) = -2 \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0 \quad (1) \right.$$

$$\left\{ \frac{\partial Q}{\partial \beta_1}(\hat{\beta}_0, \hat{\beta}_1) = -2 \sum_{i=1}^n x_i (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0 \quad (2) \right.$$

$$\left\{ \bar{y} - \hat{\beta}_0 - \hat{\beta}_1 \bar{x} = 0 \therefore \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} \quad (1') \right.$$

$$\left\{ \sum_{i=1}^n x_i y_i - \hat{\beta}_0 \sum_{i=1}^n x_i - \hat{\beta}_1 \sum_{i=1}^n x_i^2 = 0 \quad (2') \right.$$

Reemplazando  $\hat{\beta}_0$  de (1') en (2') y despejando, se tiene que

$$\sum_{i=1}^n x_i y_i - (\bar{y} - \hat{\beta}_1 \bar{x}) \sum_{i=1}^n x_i - \hat{\beta}_1 \sum_{i=1}^n x_i^2 = 0$$

$$\sum_{i=1}^n x_i y_i - n\bar{x}\bar{y} - n\hat{\beta}_1 \bar{x}^2 - \hat{\beta}_1 \sum_{i=1}^n x_i^2 = 0 \therefore \hat{\beta}_1 = \frac{\sum_{i=1}^n x_i y_i - n\bar{x}\bar{y}}{\sum_{i=1}^n x_i^2 - n\bar{x}^2} = \frac{\sum_{i=1}^n (x_i - \bar{x}) y_i}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

# Solución del problema de minimización (II)

## 2. Mínimo local (y global).

$$\begin{cases} \frac{\partial^2 Q}{\partial \beta_0^2}(\hat{\beta}_0, \hat{\beta}_1) = -2 \sum_{i=1}^n (-1) = 2n \\ \frac{\partial^2 Q}{\partial \beta_1^2}(\hat{\beta}_0, \hat{\beta}_1) = -2 \sum_{i=1}^n x_i (-x_i) = 2 \sum_{i=1}^n x_i^2 \\ \frac{\partial^2 Q}{\partial \beta_0 \partial \beta_1}(\hat{\beta}_0, \hat{\beta}_1) = 2 \sum_{i=1}^n x_i \end{cases} \quad \mathbf{J} = \begin{pmatrix} 2n & 2 \sum_{i=1}^n x_i \\ 2 \sum_{i=1}^n x_i & 2 \sum_{i=1}^n x_i^2 \end{pmatrix}$$

Luego, por el criterio de Sylvester, como

$$2n > 0 \text{ y } \det(\mathbf{J}) = 4n \sum_{i=1}^n x_i^2 - 4n^2 \bar{x}^2 = 4n \sum_{i=1}^n (x_i - \bar{x})^2 > 0;$$

por ende,  $\mathbf{J}$  es positiva definida, lo que implica que la solución es un mínimo local.

Como  $\mathbf{J}$  no depende de  $\hat{\beta}_0, \hat{\beta}_1$ ; quiere decir que  $Q$  es convexa y eso hace que la solución sea global.

No es difícil ver que  $\lim_{\|\beta\| \rightarrow \infty} Q(\beta_0, \beta_1) = \infty$ ; lo que completa la prueba.

# Una definición importante y un lema

## *Mejor estimador linealmente insesgado (BLUE)*

Sean  $Y_1, Y_2, \dots, Y_n$  variables aleatorias involucradas en un proceso de estimación. Se dice que un estimador de la forma  $\sum_{i=1}^n \phi_i Y_i$  con constantes  $\phi_i$  no aleatorias y conocidas es un **BLUE** si

- 1) es un estimador insesgado,
- 2) es el estimador con menor varianza dentro de todos los estimadores lineales insesgados.

❖ Como siempre la definición no es constructiva. Usaremos el lema del máximo (Lema 11.2.7 de Casella & Berger) más adelante para verificar que un estimador es BLUE.



Best (mejor)

Linear (lineal)

Unbiased (insesgado)

$\Sigma$  estimator

$\hat{\theta}$  es un BLUE de  $\theta$

$\text{Var}(\hat{\theta})$  es la mínima

$$\hat{\theta} = \sum_{i=1}^n \phi_i Y_i$$

$$E[\hat{\theta}] = \theta$$

# Coeficientes de regresión (I)

## Teorema de Gauss-Markov

La solución al problema de minimización propuesto es:

$$\begin{cases} \hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x}_n) Y_i}{\sum_{i=1}^n (x_i - \bar{x}_n)^2} , \\ \hat{\beta}_0 = \bar{Y}_n - \hat{\beta}_1 \bar{x}_n \end{cases}$$

$$\begin{array}{ccc} \hat{\beta}_1 & \xrightarrow[n \rightarrow \infty]{p} & \beta_1 \\ \hat{\beta}_0 & \xrightarrow[n \rightarrow \infty]{p} & \beta_0 \end{array}$$

bajo las condiciones del método descrito anteriormente, corresponde a los mejores estimadores linealmente insesgados de los parámetros del modelo de regresión lineal simple.

Además, son consistentes y tienen distribuciones asintóticas normales (por el TCL de Hájek - Sidak).

# Idea de la prueba (I)

Es claro que los estimadores encontrados son lineales.

$$\begin{cases} \hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x}_n) Y_i}{\sum_{i=1}^n (x_i - \bar{x}_n)^2} = \sum_{i=1}^n c_i Y_i, \text{ con } c_i = \frac{(x_i - \bar{x}_n)}{\sum_{i=1}^n (x_i - \bar{x}_n)^2} \\ \hat{\beta}_0 = \bar{Y}_n - \hat{\beta}_1 \bar{x}_n = \frac{1}{n} \sum_{i=1}^n Y_i - \bar{x}_n \sum_{i=1}^n c_i Y_i = \sum_{i=1}^n \left( \frac{1}{n} - \bar{x}_n c_i \right) Y_i \end{cases}$$

Linealidad ✓

Ahora, vamos a probar que son insesgados:

$$E[\hat{\beta}_1] = \frac{\sum_{i=1}^n (x_i - \bar{x}_n) E[Y_i]}{\sum_{i=1}^n (x_i - \bar{x}_n)^2} = \frac{\sum_{i=1}^n (x_i - \bar{x}_n) (\beta_0 + \beta_1 x_i)}{\sum_{i=1}^n (x_i - \bar{x}_n)^2} = \frac{\beta_0 \sum_{i=1}^n (x_i - \bar{x}_n) + \beta_1 \sum_{i=1}^n x_i (x_i - \bar{x}_n)}{\sum_{i=1}^n (x_i - \bar{x}_n)^2} = \beta_1.$$

$$E[\hat{\beta}_0] = E[\bar{Y}_n] - E[\hat{\beta}_1] \bar{x}_n = \frac{1}{n} \sum_{i=1}^n (\beta_0 + \beta_1 x_i) - \beta_1 \bar{x}_n = \frac{1}{n} n \beta_0 + \beta_1 \bar{x}_n - \beta_1 \bar{x}_n = \beta_0.$$

Insigamient. ✓

# Idea de la prueba (II)

Centremos la atención en el proceso de estimación de  $\beta_1$ .

Todo estimador lineal  $\tilde{\beta}_1$  debe ser de la forma  $\tilde{\beta}_1 = \sum_{i=1}^n \phi_i Y_i$ .

Para ser insesgado, debe satisfacer que  $E[\tilde{\beta}_1] = \sum_{i=1}^n \phi_i E[Y_i] = \beta_1$ .

De este modo, debe satisfacer que  $\sum_{i=1}^n \phi_i (\beta_0 + \beta_1 x_i) = \beta_0 \sum_{i=1}^n \phi_i + \beta_1 \sum_{i=1}^n \phi_i x_i = \beta_1$ .

De allí se obtienen dos restricciones para los coeficientes:

$$(1) \sum_{i=1}^n \phi_i = 0, \quad (2) \sum_{i=1}^n \phi_i x_i = 1.$$

*independent*

$$\text{Ahora, } \text{Var}(\tilde{\beta}_1) = \text{Var}\left(\sum_{i=1}^n \phi_i Y_i\right) = \sum_{i=1}^n \phi_i^2 \text{Var}(Y_i) = \sigma^2 \sum_{i=1}^n \phi_i^2.$$

Por ende, un BLUE se puede encontrar solucionando el problema de minimizar

$\sum_{i=1}^n \phi_i^2$  sujeto a las restricciones (1) y (2). El lema del máximo garantiza que dicha solución

es la que se obtiene con el estimador de mínimos cuadrados.

Todo estimador linealmente sesgado de  $\beta_1$

$$\tilde{\beta}_1 = \sum_{i=1}^n \phi_i Y_i$$

$$(1) \text{Var}(\tilde{\beta}_1) = \sigma^2 \sum_{i=1}^n \phi_i^2$$

(2) Para que sea sesgado  $\Rightarrow$

$$(1) \quad \begin{aligned} \sum \phi_i &= 0 \\ \sum \phi_i x_i &= 1 \end{aligned}$$

$$\begin{aligned} \min \quad & \sigma^2 \sum_{i=1}^n \phi_i^2 \\ \text{s.t.} \quad & \sum \phi_i = 0 \\ & \sum \phi_i x_i = 1 \end{aligned}$$

TAREA: Resolver el problema de minimización y ver que  $\phi_i = c_i \cdot (\text{de } \hat{\beta}_1)$

# Coeficientes de regresión (II)

## Teorema de Gauss-Markov (II)

Si además se tiene que  $\{\varepsilon_i\}$  son una m.a.  $N(0, \sigma^2)$ ,  $\hat{\beta}_0$  y  $\hat{\beta}_1$  son <sup>1</sup>UMVUEs de sus respectivos parámetros y son los mismos estimadores ML. Además, tienen distribución normal bivariada con <sup>2</sup>

$$(\hat{\beta}_0, \hat{\beta}_1)^T \sim MVN_2 \left( \begin{pmatrix} \beta_0 \\ \beta_1 \end{pmatrix}, \begin{pmatrix} \frac{\sigma^2 \sum_{i=1}^n x_i^2}{n \sum_{i=1}^n (x_i - \bar{x}_n)^2} & \frac{-\bar{x}_n \sigma^2}{\sum_{i=1}^n (x_i - \bar{x}_n)^2} \\ \frac{-\bar{x}_n \sigma^2}{\sum_{i=1}^n (x_i - \bar{x}_n)^2} & \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x}_n)^2} \end{pmatrix} \right)$$

# Idea de la prueba (I)

Si  $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n$  son una m.a.  $N(0, \sigma^2)$ ;  $Y_1, Y_2, \dots, Y_n$  heredan esa normalidad y son independientes entre sí,  $Y_i \sim N(\beta_0 + \beta_1 x_i, \sigma^2)$ . Entonces,

$$L(\beta_0, \beta_1, \sigma^2 | \mathbf{y}, \mathbf{x}) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma}} \exp\left[-\frac{(y_i - \beta_0 - \beta_1 x_i)^2}{2\sigma^2}\right] \mathbf{y}$$

$$l(\beta_0, \beta_1, \sigma^2 | \mathbf{y}, \mathbf{x}) = -\frac{n}{2} \ln 2\pi - n \ln \sigma - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2.$$

Para estimar a  $\beta_0, \beta_1$ :

$$\begin{aligned} \max l(\beta_0, \beta_1, \sigma^2 | \mathbf{y}, \mathbf{x}) &= \max \left\{ -\frac{n}{2} \ln 2\pi - n \ln \sigma - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2 \right\} \\ &= \max \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2 \right\} = \min \left\{ \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2 \right\}. \end{aligned}$$

Luego, los estimadores ML coinciden con los estimadores MCO (OLS en inglés).

# Idea de la prueba (II)

Retomando la densidad de  $Y$ , se puede ver que este modelo pertenece a la fam.

exponencial de densidades triparamétrica con  $\boldsymbol{\theta} = (\beta_0, \beta_1, \sigma^2)^T$  porque

$$f_{Y_i}(y_i, \boldsymbol{\theta}) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left[\frac{-(y_i - \beta_0 - \beta_1 x_i)^2}{2\sigma^2}\right]$$
$$= \frac{1}{\sqrt{2\pi}\sigma} \exp\left[\frac{-y_i^2}{2\sigma^2} + \frac{y_i(\beta_0 + \beta_1 x_i)}{\sigma^2} - \frac{(\beta_0 + \beta_1 x_i)^2}{2\sigma^2}\right]. \text{ De donde se tiene:}$$

$$a(\boldsymbol{\theta}) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left[-\frac{(\beta_0 + \beta_1 x_i)^2}{2\sigma^2}\right], \quad b(y) = 1,$$

$$\mathbf{c}(\boldsymbol{\theta}) = \left(\frac{-1}{2\sigma^2}, \frac{\beta_0}{\sigma^2}, \frac{\beta_1}{\sigma^2}\right)^T, \quad \mathbf{d}(y) = (y_i^2, y_i, x_i y_i)^T.$$

Luego,  $\mathbf{d}(\mathbf{y}) = \left(\sum_{i=1}^n y_i^2, \sum_{i=1}^n y_i, \sum_{i=1}^n x_i y_i\right)^T$  es un vector de estadísticas suficientes y completas.

Como  $\hat{\beta}_0, \hat{\beta}_1$  son insesgados y función de  $\mathbf{d}(\mathbf{y})$ , estos son UMVUEs.



La normalidad multivariada se probará más adelante.

Finalmente,

$$\bullet \text{ } Var(\hat{\beta}_1) = Var\left(\frac{\sum_{i=1}^n (x_i - \bar{x}_n) Y_i}{\sum_{i=1}^n (x_i - \bar{x}_n)^2}\right) = \frac{\sum_{i=1}^n (x_i - \bar{x}_n)^2 Var[Y_i]}{\left\{\sum_{i=1}^n (x_i - \bar{x}_n)^2\right\}^2} = \frac{\sum_{i=1}^n (x_i - \bar{x}_n)^2 \sigma^2}{\left\{\sum_{i=1}^n (x_i - \bar{x}_n)^2\right\}^2} = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x}_n)^2}.$$

$$\bullet \text{ } Var(\hat{\beta}_0) = Var(\bar{Y}_n - \hat{\beta}_1 \bar{x}_n) = Var(\bar{Y}_n) + \bar{x}_n^2 Var(\hat{\beta}_1) - 2Cov(\bar{Y}_n, \hat{\beta}_1 \bar{x}_n)$$

$$= \frac{\sigma^2}{n} + \frac{\bar{x}_n^2 \sigma^2}{\sum_{i=1}^n (x_i - \bar{x}_n)^2} - 2\bar{x}_n Cov(\bar{Y}_n, \hat{\beta}_1)$$

$$= \sigma^2 \left[ \frac{\sum_{i=1}^n (x_i - \bar{x}_n)^2 + n\bar{x}_n^2}{n \sum_{i=1}^n (x_i - \bar{x}_n)^2} \right] - 2\bar{x}_n Cov\left(\frac{1}{n} \sum_{i=1}^n Y_i, \frac{\sum_{i=1}^n (x_i - \bar{x}_n) Y_i}{\sum_{i=1}^n (x_i - \bar{x}_n)^2}\right)$$

$$= \sigma^2 \left[ \frac{\sum_{i=1}^n x_i^2}{n \sum_{i=1}^n (x_i - \bar{x}_n)^2} \right] - \frac{2\bar{x}_n}{n \sum_{i=1}^n (x_i - \bar{x}_n)^2} Cov\left(\sum_{i=1}^n Y_i, \sum_{i=1}^n (x_i - \bar{x}_n) Y_i\right)$$

$$\begin{aligned}
&= \sigma^2 \left[ \frac{\sum_{i=1}^n x_i^2}{n \sum_{i=1}^n (x_i - \bar{x}_n)^2} \right] - \frac{2\bar{x}_n}{n \sum_{i=1}^n (x_i - \bar{x}_n)^2} \sum_{i=1}^n \sum_{j=1}^n \text{Cov}(Y_i, (x_j - \bar{x}_n) Y_j) \\
&= \sigma^2 \left[ \frac{\sum_{i=1}^n x_i^2}{n \sum_{i=1}^n (x_i - \bar{x}_n)^2} \right] - \frac{2\bar{x}_n}{n \sum_{i=1}^n (x_i - \bar{x}_n)^2} \sum_{i=1}^n \text{Cov}(Y_i, (x_i - \bar{x}_n) Y_i) \\
&= \sigma^2 \left[ \frac{\sum_{i=1}^n x_i^2}{n \sum_{i=1}^n (x_i - \bar{x}_n)^2} \right] - \frac{2\bar{x}_n}{n \sum_{i=1}^n (x_i - \bar{x}_n)^2} \sum_{i=1}^n (x_i - \bar{x}_n) \underbrace{\text{Cov}(Y_i, Y_i)}_{= \text{Var}(Y_i) = \sigma^2} = \sigma^2 \left[ \frac{\sum_{i=1}^n x_i^2}{n \sum_{i=1}^n (x_i - \bar{x}_n)^2} \right].
\end{aligned}$$

$$\bullet \text{Cov}(\hat{\beta}_0, \hat{\beta}_1) = \text{Cov}(\bar{Y}_n - \hat{\beta}_1 \bar{x}_n, \hat{\beta}_1) = \text{Cov}(\bar{Y}_n, \hat{\beta}_1) - \text{Cov}(\hat{\beta}_1 \bar{x}_n, \hat{\beta}_1)$$

$$= 0 - \bar{x}_n \text{Cov}(\hat{\beta}_1, \hat{\beta}_1) = -\bar{x}_n \text{Var}(\hat{\beta}_1) = \left[ \frac{-\bar{x}_n \sigma^2}{\sum_{i=1}^n (x_i - \bar{x}_n)^2} \right].$$

# Coeficientes de regresión (III)

Bajo normalidad, el estimador ML de  $\sigma^2$  es

$$\hat{\sigma}_{ML}^2 = \frac{1}{n} \sum_{i=1}^n \left( Y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i \right)^2,$$

sin embargo, este estimador es sesgado. Un estimador insesgado de la varianza es

$$\hat{\sigma}^2 = \frac{1}{n-2} \sum_{i=1}^n \left( Y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i \right)^2. \text{ Sobre este estimador, es posible}$$

probar que:

$$\frac{(n-2)\hat{\sigma}^2}{\sigma^2} \sim \chi^2(n-2), \text{ y es independiente de } \hat{\beta}_0 \text{ y } \hat{\beta}_1.$$

❖ Se probará más adelante su insesgamiento, su distribución y su independencia.

# Intervalos de confianza para los coeficientes de regresión bajo normalidad

$$\frac{\hat{\beta}_1 - \beta_1}{\sqrt{\text{Var}(\hat{\beta}_1)}} = \sqrt{\sum_{i=1}^n (x_i - \bar{x}_n)^2} \left( \frac{\hat{\beta}_1 - \beta_1}{\sigma} \right) \sim N(0,1)$$

*indep.*  
 $\perp \quad \frac{(n-2)\hat{\sigma}^2}{\sigma^2} \sim \chi^2(n-2)$

$$\frac{\hat{\beta}_0 - \beta_0}{\sqrt{\text{Var}(\hat{\beta}_0)}} = \sqrt{\frac{n \sum_{i=1}^n (x_i - \bar{x}_n)^2}{\sum_{i=1}^n x_i^2}} \left( \frac{\hat{\beta}_0 - \beta_0}{\sigma} \right) \sim N(0,1)$$

❖ **Cantidad pivote:**

$$\frac{\hat{\beta}_i - \beta_i}{\sqrt{\text{Var}(\hat{\beta}_i)}} \sim t(n-2)$$

$$IC_{100(1-\alpha)\%}(\beta_i) = \hat{\beta}_i \mp t_{1-\frac{\alpha}{2}}(n-2) \sqrt{\text{Var}(\hat{\beta}_i)}$$

# Pruebas de hipótesis para los coeficientes de regresión bajo normalidad

(Sist. a dos colas)    (Sist. con cola a derecha)    (Sist. con cola a izquierda)

$$\begin{cases} H_0 : \beta_i = \tilde{\beta} \\ \text{versus} \\ H_1 : \beta_i \neq \tilde{\beta} \end{cases}$$

$$\begin{cases} H_0 : \beta_i \leq \tilde{\beta} \\ \text{versus} \\ H_1 : \beta_i > \tilde{\beta} \end{cases}$$

$$\begin{cases} H_0 : \beta_i \geq \tilde{\beta} \\ \text{versus} \\ H_1 : \beta_i < \tilde{\beta} \end{cases}$$

❖ **Valor calculado:**  $t_C = \frac{\hat{\beta}_i - \tilde{\beta}}{\sqrt{\hat{Var}(\hat{\beta}_i)}}$

❖ **Regla de decisión:**

(Sist. a dos colas)    (Sist. con cola a derecha)    (Sist. con cola a izquierda)

$\tau$ : "Rechazar  $H_0$  si

$$|t_C| > t_{1-\frac{\alpha}{2}}(n-2)"$$

$$t_C > t_{1-\alpha}(n-2)"$$

$$t_C < t_{\alpha}(n-2)"$$

$p$ -values =

$$2p(T_C > |t_C| | H_0)$$

$$p(T_C > t_C | H_0)$$

$$p(T_C < t_C | H_0)$$

# Intervalos de confianza para la media

$\mu_i = \beta_0 + \beta_1 x_i$  : Valor esperado para una unidad con valor  $x_i$  de la covariable.

$\hat{\mu}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$  : Estimación puntual.

$$E[\hat{\mu}_i] = E[\hat{\beta}_0 + \hat{\beta}_1 x_i] = \beta_0 + \beta_1 x_i = \mu_i$$

$$Var[\hat{\mu}_i] = Var[\hat{\beta}_0 + \hat{\beta}_1 x_i] = Var(\hat{\beta}_0) + x_i^2 Var(\hat{\beta}_1) + 2x_i \text{cov}(\hat{\beta}_0, \hat{\beta}_1)$$

$$\hat{\mu}_i \sim N(\mu_i, Var[\hat{\mu}_i])$$

❖ **Cantidad pivote:**

$$\frac{\hat{\mu}_i - \mu_i}{\sqrt{\hat{Var}(\hat{\mu}_i)}} \sim t(n-2)$$

$$IC_{100(1-\alpha)\%}(\mu_i) = \hat{\mu}_i \mp t_{1-\frac{\alpha}{2}}(n-2) \sqrt{\hat{Var}(\hat{\mu}_i)}$$

# Intervalos de predicción

Sea  $x^*$  el valor de la covariable para una **nueva unidad** de la cual no se conoce su respuesta  $Y^*$ . ¿Cómo construir un int. de **predicción** para  $Y^*$ ?

$\mu^* = \beta_0 + \beta_1 x^*$  : Valor esperado para una unidad con valor  $x^*$ .

$$\hat{\mu}^* \sim N(\mu^*, \text{Var}[\hat{\mu}^*])$$

$$\text{Sea } e^* = Y^* - \hat{\mu}^*$$

$$E[e^*] = E[Y^* - \hat{\mu}^*] = 0$$

$$\text{Var}[e^*] = \text{Var}[Y^* - \hat{\mu}^*] = \text{Var}(Y^*) + \text{Var}[\hat{\mu}^*] = \sigma^2 + \text{Var}[\hat{\mu}^*]$$

$$e^* \sim N(0, \sigma^2 + \text{Var}[\hat{\mu}^*])$$

❖ **Cantidad pivote:**

$$\frac{e^*}{\sqrt{\hat{\sigma}^2 + \hat{\text{Var}}(\hat{\mu}^*)}} \sim t(n-2) \quad IP_{100(1-\alpha)\%}(Y^*) = \hat{\mu}^* \mp t_{1-\frac{\alpha}{2}}(n-2) \sqrt{\hat{\sigma}^2 + \hat{\text{Var}}(\hat{\mu}^*)}$$