

# Probabilidad - II 2024

## Universidad Nacional de Colombia - Dic 14

Tutor: Carlos E. Alonso–Malaver.

ö. Para masticar-rumiar:

Yo soy yo mismo,  
Pero no el mismo...  
**Reguetonero - Brazil**

## Distribuciones Multivariadas

### Contexto General

1. De Forma sencilla

- Sea  $U = (\Omega, \mathfrak{F}, P)$  espacio de probabilidad.
- Las variables aleatorias  $X_1, X_2, \dots, X_p$  están definidas sobre  $U$ ,  $p \geq 2$ .
- Definido el vector  $\mathbf{X} := (X_1, X_2, \dots, X_p)$
- El propósito es Estudiar  $P(\mathbf{X} \in B)$ ,  $B \subset \mathbb{R}^p$ .

2. Si has entendido las distribuciones bivariadas, lo básico para trabajar probabilidad en el mundo multivariado  $p \geq 2$  se presenta a continuación:

- Dado un vector discreto, i.e. sus componentes son v.a. discretas,
  - Su función de masa de probabilidad conjunta  $f_{\mathbf{x}}$ , nos dice:

$$f_{\mathbf{x}}(\mathbf{x}) = P(\mathbf{X} = \mathbf{x}) = P(X_1 = x_1, X_2 = x_2, \dots, X_p = x_p) \quad \mathbf{x} \in \mathbb{R}^p.$$

- De lo anterior, dado  $B \subset \mathbb{R}^p$ ,

$$P(\mathbf{X} \in B) = \sum_{\mathbf{x} \in B} f_{\mathbf{x}}(\mathbf{x}).$$

- En particular  $F_{\mathbf{x}}(\mathbf{x}_0) = P(\mathbf{X} \leq \mathbf{x}_0) = \sum_{\mathbf{x} \leq \mathbf{x}_0} f_{\mathbf{x}}(\mathbf{x})$ .
- En el caso de un vector aleatorio continuo, i.e. sus componentes son v.a. continuas,
  - Se hace uso de una función de densidad conjunta  $f_{\mathbf{x}}$
  - Dado un Boreliano  $B \subset \mathbb{R}^p$ ,

$$P(\mathbf{X} \in B) = \int_{\mathbf{x} \in B} f_{\mathbf{x}}(\mathbf{x}) d\mathbf{x}$$

- En particular

$$\begin{aligned} F_{\mathbf{x}}(\mathbf{x}) &= P(\mathbf{X} \leq \mathbf{x}) = \int_{-\infty}^{\mathbf{x}} f_{\mathbf{x}}(\mathbf{x}) d\mathbf{x} \\ &= \int_{-\infty}^{x_1} \int_{-\infty}^{x_2} \cdots \int_{-\infty}^{x_p} f_{\mathbf{x}}(\mathbf{x}) dx_1 dx_2 \dots dx_p. \end{aligned}$$

- **Ejemplo 1:** Dadas  $X, Y, Z$  v.a. continuas con f.d. conjunta dada por:

$$f_{X,Y,Z}(x, y, z) = \frac{12}{7}(x + 2y + 3z)I_{\{0 < x \leq y \leq z < 1\}}(x, y, z).$$

Asume se desea llegar  $g_{Z|X=x, Y=y}(z)$ . Este objetivos nos permite trabajar los conceptos ya desarrollos en el caso bivariado.

Previo, se requiere  $f_{X,Y}(x, y)$ , veamos:

$$\begin{aligned} f_{X,Y}(x, y) &= \frac{12}{7} \int_y^1 (x + 2y + 3z) dz \\ &= \frac{12}{7} \left[ x + (2 - x)y - \frac{7y^2}{2} + \frac{3}{2} \right] I_{\{0 < x \leq y < 1\}}(x, y) \end{aligned}$$

Usando lo anterior:

$$\begin{aligned}
 g_{Z|X=x,Y=y}(z) &= \frac{f_{X,Y,Z}(x,y,z)}{f_{X,Y}(x,y)} \\
 &= \frac{\frac{12}{7}(x+2y+3z)}{\frac{12}{7}\left[x+(2-x)y-\frac{7y^2}{2}+\frac{3}{2}\right]} \\
 &= \frac{x+2y+3z}{x+(2-x)y-\frac{7y^2}{2}+\frac{3}{2}} I_{\{y \leq z < 1\}}(z), \quad 0 \leq x \leq y
 \end{aligned}$$

Lo anterior para,  $x = \frac{1}{3}$  y  $y = \frac{1}{2}$

$$\begin{aligned}
 g_{Z|X=\frac{1}{4},Y=\frac{1}{2}}(z) &= \frac{\frac{1}{4}+2\frac{1}{2}+3z}{\frac{1}{4}+(2-\frac{1}{4})\frac{1}{2}-\frac{7\frac{1}{2^2}}{2}+\frac{3}{2}} I_{\{\frac{1}{2} \leq z < 1\}}(z) \\
 &= \frac{4}{7} \left( \frac{5}{4} + 3z \right) I_{\{\frac{1}{2} \leq z < 1\}}(z)
 \end{aligned}$$

**Verifica** que  $g_{Z|X=\frac{1}{4},Y=\frac{1}{2}}(z)$  es función de densidad.

- De forma análoga se puede hallar  $f_X(x)$ ,  $f_Y(y)$ ,  $f_Z(z)$ ,

$$\begin{aligned}
 f_X(x) &= \frac{12}{7} \int_x^1 \int_y^1 x+2y+3z \, dz \, dy \\
 &= \frac{12}{7} \left( \frac{4}{3} - x - 2x^2 + \frac{5}{3}x^3 \right) I_{\{0 < x < 1\}}(x)
 \end{aligned}$$

- Obtenidas  $f_X(x)$  y  $f_{X,Y,Z}(x,y,z)$  podemos hallar

$$g_{Y,Z|X=x}(y,z) = \frac{f_{X,Y,Z}(x,y,z)}{f_X(x)},$$

que es una función de **densidad bivariada condicional**.

- **En resumen:** si tenemos  $f_{X,Y,Z}(x,y,z)$ , podemos derivar la siguiente información:
  - Las marginales bivariadas  $f_{X,Y}(x,y)$ ,  $f_{X,Z}(x,z)$  y  $f_{Y,Z}(y,z)$ .
  - Las marginales univariadas  $f_X(x)$ ,  $f_Y(y)$  y  $f_Z(z)$ .

- Las condicionales bivariadas  $g_{X,Y|Z=z}(x,y)$ ,  $g_{X,Z|Y=y}(x,z)$  y  $g_{Y,Z|X=x}(y,z)$ .
  - Las condicionales univariadas  $g_{X|Y=y,Z=z}(x)$ ,  $g_{Y|X=x,Z=z}(y)$  y  $g_{Z|X=x,Y=y}(z)$ .
  - Una forma más general del resultado anterior es, si se tiene un vector aleatorio  $\mathbf{X} = (X_1, X_2, \dots, X_p)$  con función de masa o densidad conjunta  $f_{\mathbf{X}}(\mathbf{x})$ , si particionamos el vector  $\mathbf{X} = (\mathbf{X}_1, \mathbf{X}_2)$ , para cada componente se puede obtener
    - Las funciones de masa o densidad marginales, i.e.  $f_{\mathbf{X}_j}(\mathbf{x})$ ,  $j = 1, 2$ .
    - Las funciones de masa o densidad condicional, i.e.  $g_{\mathbf{X}_i|\mathbf{X}_j=u}(x|u)$ ;  $i, j = 1, 2, i \neq j$ .
  - En el caso continuo, i.e. el vector aleatorio  $\mathbf{X} = (X_1, X_2, \dots, X_p)$  continuo, con funciones de densidad y de distribución conjunta  $f_{\mathbf{X}}(\cdot)$  y  $F_{\mathbf{X}}(\cdot)$ , se cumple:
    - $F_{\mathbf{X}}(\mathbf{x}) = \int_{-\infty}^{\mathbf{x}} f_{\mathbf{X}}(\mathbf{u}) d\mathbf{u}$ .
    - $f_{\mathbf{X}}(\mathbf{x}) = \frac{\partial^p}{\partial x_p \dots \partial x_1} F_{\mathbf{X}}(\mathbf{x})$ .
3. Distribuciones Multivariadas - **Independencia**: si las v.a.  $X_1, X_2, \dots, X_p$ , son independientes entonces:

■

$$F_{\mathbf{X}}(\mathbf{x}) = F_{X_1}(x_1)F_{X_2}(x_2) \dots F_{X_p}(x_p) \quad (1)$$

■

$$f_{\mathbf{X}}(\mathbf{x}) = f_{X_1}(x_1)f_{X_2}(x_2) \dots f_{X_p}(x_p) \quad (2)$$

Donde  $\mathbf{X} = (X_1, X_2, \dots, X_p)$ . Si se cumplen las Ec. 1 y 2 entonces  $X_1, X_2, \dots, X_p$  son v.a. independientes.

## Transformación de Variables Aleatorias

1. De Forma sencilla:

$$(\Omega, \mathfrak{F}, P) \xrightarrow{X} (\mathbb{R}, \mathfrak{B}, P_X) \xrightarrow{Y:=r(X)} (\mathbb{R}, \mathfrak{B})$$

- Asume se tiene una v.a.  $X$  para la que se conoce su ley de distribución  $P_X$ .

- El interés recae sobre una transformación de  $X$ , esto es  $Y = r(X)$ .
- El propósito inicial es hallar  $P_Y$ .

2. **Caso Discreto:** en el caso de una variable aleatoria discreta el truco es devolverse al espacio inicial (usando inversa de conjuntos), lo que significa:

- Dada una variable aleatoria discreta  $X$ , con función de masa de probabilidad  $f_X(x) = P(X = x)$ .
- Si se define  $Y = r(X)$ , se tiene que la función de masa de probabilidad de  $Y$ ,  $f_Y(y) = P(Y = y)$ , está dada por:

$$f_Y(y) = P(Y = y) = \sum_{x:r(x)=y} P(X = x) = \sum_{x:r(x)=y} f_X(x)$$

- **Ejemplo 2.** Veamos lo anterior mediante un ejemplo pedagógico.
  - $X$  variable aleatoria que toma valores en el conjunto  $\{1, 2, 3, \dots, 20\}$ , con función de masa de probabilidad

$$f_X(x) = P(X = x) = \frac{x}{210}.$$

- Si se define  $Y = r(X)$ , donde  $r(x) := \text{Número de divisores del número } x$ , hallemos  $f_Y(\cdot)$ .
- Veamos:
  - Los divisores del número  $x = 7$  son  $\{1, 7\}$  de donde  $Y|_{X=7} = r(7) = 2$
  - Los divisores del número  $x = 12$  son  $\{1, 2, 3, 4, 6, 12\}$  de donde  $Y|_{X=12} = r(12) = 6$
- Observa y colige:
  - $Y = 1, 2, \dots, 6$ , posibles valores de la v.a.  $Y$
  - $Y^{-1}(\{1\}) = \{1\}$ , aquí piensa en los números que tienen un sólo divisor.
  - $Y^{-1}(\{2\}) = \{2, 3, 5, 7, 11, 13, 17, 19\}$  (números primos menores de 20)
  - $Y^{-1}(\{3\}) = \{4, 9\}$ , análogo, piensa en los números que tienen tres divisores.

Si lo anterior es claro:

$$\circ f_Y(1) = f_X(1) = \frac{1}{210}$$

$$\circ$$

$$\begin{aligned} f_Y(2) &= f_X(2) + f_X(3) + f_X(5) + f_X(7) + f_X(11) \\ &\quad + f_X(13) + f_X(17) + f_X(19) \\ &= \frac{2}{210} + \frac{3}{210} + \dots + \frac{19}{210} = \frac{77}{210} \end{aligned}$$

$$\circ f_Y(3) = f_X(4) + f_X(9) = \frac{13}{210}$$

$$\circ f_Y(5) = f_X(16) + f_X(20) = \frac{36}{210}$$

En resumen:

$$f_X(x) = \begin{cases} \frac{x}{210} & \text{si } x = 1, 2, \dots, 20 \\ 0 & \text{e.o.c.} \end{cases}$$

Si se define  $Y := r(X)$ , con  $r(X) :=$ número de divisores de  $X$ , entonces

$$f_Y(y) = \begin{cases} \frac{1}{210} & \text{si } y = 1 \\ \frac{77}{210} & \text{si } y = 2 \\ \frac{13}{210} & \text{si } y = 3 \\ \frac{53}{210} & \text{si } y = 4 \\ \frac{36}{210} & \text{si } y = 5 \\ \frac{30}{210} & \text{si } y = 6 \\ 0 & \text{e.o.c.} \end{cases}$$

3. **Caso Continuo:** Iniciaremos éste caso mediante un ejemplo,

- Sea  $U \sim U(0, 1)$ .
- Nos interesa la variable aleatoria  $Y = -\beta \ln(1 - U)$ , donde  $\beta > 0$ .
- Nuestro objetivo es: hallar  $F_Y$  o  $f_Y$  (hallaremos ambas)
- De partida **se tiene:**

$$f_U(u) := I_{(0,1)}(u) \quad \text{y} \quad F_U(u) := P(U \leq u) = \begin{cases} 0 & \text{si } u < 0 \\ x & \text{si } 0 \leq u < 1 \\ 1 & \text{si } u > 1 \end{cases}$$

Para el comportamiento de  $Y$  observa

- a) Si  $U \in (0, 1)$  entonces  $1 - U \in (0, 1)$ .
- b) De lo anterior  $\ln(1 - U) \in (-\infty, 0)$ .
- c) Entonces  $Y = -\beta \ln(1 - U) \in (0, \infty)$ ,  $\beta > 0$ .

Ahora:

$$\begin{aligned}
F_Y(y) &:= P(Y \leq y) = P(-\beta \ln(1 - U) \leq y) \\
&= P(\ln(1 - U) \geq -\frac{y}{\beta}) = P(1 - U \geq e^{-\frac{y}{\beta}}) \\
&= P(U \leq 1 - e^{-\frac{y}{\beta}}) = F_U(1 - e^{-\frac{y}{\beta}}) \\
&= \begin{cases} 0 & \text{si } 1 - e^{-\frac{y}{\beta}} < 0 \\ 1 - e^{-\frac{y}{\beta}} & \text{si } 0 \leq 1 - e^{-\frac{y}{\beta}} < 1 \\ 1 & \text{si } 1 - e^{-\frac{y}{\beta}} > 1 \end{cases} \\
&= \left(1 - e^{-\frac{y}{\beta}}\right) I_{(0, \infty)}(y)
\end{aligned}$$

De las propiedades de función de densidad:

$$\begin{aligned}
f_Y(y) &= \frac{\partial F_Y(y)}{\partial y} = \frac{\partial F_U(1 - e^{-\frac{y}{\beta}})}{\partial y} \\
&= f_U(1 - e^{-\frac{y}{\beta}}) * \left(\frac{1}{\beta} e^{-\frac{y}{\beta}}\right) \\
&= \left(\frac{1}{\beta} e^{-\frac{y}{\beta}}\right) I_{(0, \infty)}(y)
\end{aligned} \tag{3}$$

Si una v.a.  $Y$  tiene densidad dada por la función en la Ec. (3) entonces la v.a.  $Y$  tiene distribución exponencial,  $Y \sim \text{Exp}(\beta)$ .

- Lo anterior es útil porque nos permite hacer simulación de Monte Carlo de una v.a. con distribución exponencial. Veamos los pasos para ello,
  - a) Genera  $u$  de acuerdo a una distribución uniforme  $(0, 1)$
  - b) Calcula  $y = -\beta \ln(1 - u)$
  - c) Los resultados anteriores nos permiten pensar que  $y$  (así definido), proviene de una distribución exponencial de parámetro  $\beta$ .
- **Generalizando:** En el ejemplo anterior se tiene que  $Y = r(U)$ , con  $r(u)$  una función 1-a-1 creciente (como función de  $u$ ), lo que podemos hallar

$r^{-1}(y) = s(y)$ , lo que a su vez nos permite generalizar lo hecho, como sigue:

**Función Creciente:** Dada  $X$  v.a. continua con función de densidad  $f_X(\cdot)$ . Si  $Y = r(U)$ , con  $r(u)$  función monótona creciente entonces

$$\begin{aligned} F_Y(y) &:= P(Y \leq y) = P(r(U) \leq y) = P(U \leq s(y)) \\ &= F_U(s(y)) \end{aligned}$$

Donde  $s(\cdot) = r^{-1}(\cdot)$ , de lo anterior

$$\begin{aligned} f_Y(y) &= \frac{\partial F_Y(y)}{\partial y} = \frac{\partial F_U(s(y))}{\partial y} \\ &= f_U(s(y)) \frac{\partial s(y)}{\partial y} = f_U(s(y)) s'(y) \end{aligned} \quad (4)$$

**Función Decreciente:** para el caso  $Y = r(U)$  función 1-a-1 decreciente (como función de  $U$ ), lo anterior es como sigue

$$\begin{aligned} F_Y(y) &:= P(Y \leq y) = P(r(U) \geq y) = 1 - P(U < s(y)) \\ &= 1 - F_U(s(y)) \end{aligned}$$

De donde:

$$\begin{aligned} f_Y(y) &= \frac{\partial F_Y(y)}{\partial y} = \frac{\partial [1 - F_U(s(y))]}{\partial y} \\ &= -f_U(s(y)) \frac{\partial s(y)}{\partial y} = f_U(s(y)) (-s'(y)) \end{aligned} \quad (5)$$

En éste caso observa  $s$  es decreciente y por ende  $s'(y)$  es una función de valor negativo.

De lo anterior, Ec. (4) y (5), **En general:** si  $Y = r(U)$ , con  $r(u)$  una función absolutamente monótona (creciente o decreciente) diferenciable, se tiene que:

$$f_Y(y) = f_U(s(y)) |s'(y)| \quad (6)$$

Donde  $|\cdot|$  indica valor absoluto.



- **Ejemplo 3:** Dada  $X$  con función de densidad

$$f_X(x) = e^{-x} I_{(0,\infty)},$$

es de interés hallar la densidad de  $Y = -X^{\frac{1}{2}}$ .

Aplicando el resultado que se presenta en la Ecuación (6):

- $r(u) = -u^{\frac{1}{2}}$ , observa es monótona decreciente.
- $s(y) = r^{-1}(y) = (-y)^2$  y  $\frac{\partial s(y)}{\partial y} = 2y < 0$ .
- De donde:

$$f_Y(y) = f_X(s(y)) |s'(y)| = -2ye^{y^2} I_{(-\infty,0)}(y)$$

- **Un Camino Alternativo:** Un camino alternativo es trabajar directamente y buscar una solución analítica. Veamos Sea  $X$  v.a. con función de densidad dada por

$$f_X(x) = \frac{1}{18} x^2 I_{(-3,3)}(x)$$

Asume se desea la función de densidad de  $Y = X^2$ .

$$\begin{aligned} F_Y(y) &= P(Y \leq y) = P(X^2 \leq y) = P(|X| \leq y^{\frac{1}{2}}) \\ &= P(-y^{\frac{1}{2}} \leq X \leq y^{\frac{1}{2}}) = P(X \leq y^{\frac{1}{2}}) - P(X \leq -y^{\frac{1}{2}}) \\ &= F_X(y^{\frac{1}{2}}) - F_X(-y^{\frac{1}{2}}) \end{aligned}$$

De lo anterior:

$$\begin{aligned} f_Y(y) &= \frac{\partial F_Y(y)}{\partial y} = \frac{\partial [F_X(y^{\frac{1}{2}}) - F_X(-y^{\frac{1}{2}})]}{\partial y} \\ &= f_X(y^{\frac{1}{2}}) \frac{1}{2} y^{-\frac{1}{2}} + f_X(-y^{\frac{1}{2}}) \frac{1}{2} y^{-\frac{1}{2}} \\ &= \frac{1}{18} y^{\frac{1}{2}} I_{(0,9)}(y) \end{aligned}$$

## Transformación de Vectores Aleatorios

1. Iniciemos con dos [Ejemplos Distribuciones del Máximo y del Mínimo](#):  
Asume que se tiene una muestra aleatoria  $X_1, X_2, \dots, X_n$  de una población con función de distribución acumulada  $F_X(\cdot)$ , y se desea conocer la distribución del máximo y del mínimo valor observados.

**Notación:**

- $Y = X_{(n)} = \max\{X_1, X_2, \dots, X_n\}$  (Estadística de orden  $n$ ) y
- $Z = X_{(1)} = \min\{X_1, X_2, \dots, X_n\}$  (Estadística de orden 1).

**Distribución del Máximo:**

$$\begin{aligned} F_Y(y) &= P(Y \leq y) = P(X_1 \leq y, X_2 \leq y, \dots, X_n \leq y) \\ &= P(X_1 \leq y)P(X_2 \leq y) \dots P(X_n \leq y) \\ &= F_X^n(y) \end{aligned}$$

En el caso  $X$  v.a. continua con función de densidad  $f_X(\cdot)$ , se tiene:

$$f_Y(y) = nF_X^{n-1}(y)f_X(y).$$

**Distribución del Mínimo**

$$\begin{aligned} F_Z(z) &= P(Z \leq z) = 1 - P(Z > z) \\ &= 1 - P(X_1 > z, X_2 > z, \dots, X_n > z) \\ &= 1 - P(X_1 > z)P(X_2 > z) \dots P(X_n > z) \\ &= 1 - [1 - P(X_1 \leq z)][1 - P(X_2 \leq z)] \dots [1 - P(X_n \leq z)] \\ &= 1 - [1 - F_X(z)]^n \end{aligned}$$

De nuevo, en el caso  $X$  v.a. continua con función de densidad  $f_X(\cdot)$ , se tiene:

$$f_Z(z) = n[1 - F_X(z)]^{n-1}f_X(z).$$

[Aplicación:](#)

- Un caso aplicado de lo anterior es asumir que se tiene un sistema en línea que depende de  $n$  componentes (ejemplo resistencias) construídos con la misma tecnología.
- El sistema falla al fallar al menos un componente.

- Es decir, si los tiempos de sobrevida de los  $n$  componentes son  $X_1, X_2, \dots, X_n$  v.a (i.i.d.).
- El tiempo de sobrevida del sistema es

$$Z = X_{(1)} = \min\{X_1, X_2, \dots, X_n\}.$$

- Si asumimos  $X_j$  tiene distribución exponencial, con:

$$f_X(x) = \frac{1}{\beta} e^{-\frac{x}{\beta}} I_{(0,\infty)}(x).$$

$$F_X(x) = \left[1 - e^{-\frac{x}{\beta}}\right] I_{(0,\infty)}(x).$$

El tiempo antes de la primera falla del sistema tiene una distribución con función de densidad:

$$\begin{aligned} f_Z(z) &= n[1 - F_X(z)]^{n-1} f_X(z) \\ &= \frac{n}{\beta} e^{-\frac{n}{\beta}z} \end{aligned}$$

**Nota:** Lo anterior, explicado con un ejemplo sencillo, es como sigue.

- Si se tiene una resistencia cuyo tiempo antes de la primera falla,  $X$ , tiene distribución exponencial,  $X \sim \exp(12)$  (en meses). Se espera que  $X$  falle a los dos 12 meses.
- Si se monta un sistema (en línea) con 6 resistencias de las planteadas en el ítem anterior, entonces  $Z = X_{(1)} \sim \exp\left(\frac{\beta}{6}\right) = \exp(2)$ , de donde se espera que el sistema falle a los dos meses.

2. **Transformaciones 1-1.** Lo que sigue es pensar en transformaciones vectoriales 1-1, concepto que debes entender-recordar. Veamos dos ejemplos.

**Ejemplo 4:** Asumiendo se tiene dos variables aleatorias  $X, Y$ , con las que formamos el vector  $\mathbf{X} = (X, Y)$ , y conocemos la distribución de  $\mathbf{X}$ .

- A las variables  $X, Y$ , las llamaremos variables de inicio.
- Definimos (es de interés) las v.a.  $Z := r_1(\mathbf{X}) = r_1(X, Y) = X + Y$  y  $W := r_2(\mathbf{X}) = r_2(X, Y) = X - Y$ , que llamaremos variables de llegada.
- Observa  $\mathbf{Z} = (Z, W) = (r_1(\mathbf{X}), r_2(\mathbf{X})) = r(\mathbf{X})$ .

- Se tiene:  $X = \frac{Z+W}{2}$  y  $Y = \frac{Z-W}{2}$ .
- Podemos devolvernos,  $\mathbf{X} = (X, Y) = (s_1(\mathbf{Z}), s_2(\mathbf{Z})) = s(\mathbf{Z})$ .
- Para la transformación

$$r : (x, y) \rightarrow (z, w),$$

hemos hallado la transformación

$$s : (z, w) \rightarrow (x, y).$$

Entonces la transformación  $r : \mathbb{R}^2 \rightarrow \mathbb{R}^2$  es 1-1.

**Ejemplo 5:** Bajo los mismos supuestos del ejemplo anterior.

- Asumiendo  $X > 0$  y  $Y > 0$ .
- $Z = \frac{X}{Y} = r_1(\mathbf{X})$  y  $W = XY = r_2(\mathbf{X})$ , entonces  $r(\mathbf{X}) = (r_1(\mathbf{X}), r_2(\mathbf{X}))$ .
- Observa:

$$X = [ZW]^{\frac{1}{2}} \quad \text{y} \quad Y = \left[ \frac{W}{Z} \right]^{\frac{1}{2}}.$$

- De nuevo: la transformación  $r : (0, \infty)^2 \rightarrow (0, \infty)^2$  es 1-1

3. **De forma sencilla:** lo que sigue es trabajar transformación de vectores, para transformaciones 1-1. Análogo a lo hecho en v.a. tenemos un vector aleatorio  $\mathbb{X}$ ,

$$\mathbb{X} : (\Omega, \mathfrak{F}, P) \rightarrow (\mathbb{R}, \mathfrak{B}, P_{\mathbb{X}})$$

- Se conoce la distribución (conjunta) del vector  $\mathbb{X}$ ,  $P_{\mathbb{X}}$ .
- El interés recae sobre una transformación de  $\mathbb{X}$ , esto es  $\mathbb{Y} = \mathbb{T}(\mathbb{X})$ .
- El propósito es hallar  $P_{\mathbb{Y}}$ .

**Caso Discreto:** En general tenemos:

- Un vector aleatorio discreto  $\mathbb{X} = (X_1, X_2, \dots, X_n)$ , cuya función de masa de probabilidad conjunta  $f_{\mathbb{X}}(\mathbf{x}) = P(\mathbb{X} = \mathbf{x})$ , conocida.
- Si se define  $\mathbb{Y} = \mathbb{T}(\mathbb{X})$ ,

$$\mathbb{T} : \mathbb{R}^n \rightarrow \mathbb{R}^p$$

Lo que debes pensar es:

$$\mathbb{Y} = (Y_1, Y_2, \dots, Y_p) = \mathbb{T}(\mathbb{X}) = (T_1(\mathbb{X}), T_2(\mathbb{X}), \dots, T_p(\mathbb{X})).$$

En general  $p \leq n$ . Dado lo anterior, en el caso de un vector aleatorio discreto el truco es devolverse al espacio inicial (idéntico a los hecho con v.a. discretas), lo que significa:

- Es decir, la función de masa de probabilidad de  $\mathbb{Y}$ ,  $f_{\mathbb{Y}}(y)$ , está dada por:

$$f_{\mathbb{Y}}(y) = P(\mathbb{Y} = y) = \sum_{\mathbf{x}: \mathbb{T}(\mathbf{x})=y} P(\mathbb{X} = \mathbf{x}) = \sum_{\mathbf{x}: \mathbb{T}(\mathbf{x})=y} f_{\mathbb{X}}(\mathbf{x})$$

**Caso Continuo:** En el caso de los vectores aleatorios continuos se busca tener [transformaciones 1-a-1](#), ítem que ya ha sido explicado.

- Se tiene un vector aleatorio  $\mathbb{X} = (X_1, X_2, \dots, X_n)$ , cuya función de densidad de probabilidad conjunta  $f_{\mathbb{X}}(\mathbf{x})$ , conocida, y una transformación  $\mathbb{Y} = (Y_1, Y_2, \dots, Y_n) = \mathbb{T}(\mathbb{X}) = (T_1(\mathbb{X}), T_2(\mathbb{X}), \dots, T_n(\mathbb{X}))$
- Dado que  $\mathbb{T}$  es 1-a-1, existe una transformación inversa  $\mathbb{S}(\mathbb{Y}) = (S_1(\mathbb{Y}), S_2(\mathbb{Y}), \dots, S_n(\mathbb{Y})) = (X_1, X_2, \dots, X_n)$ .
- A partir de lo anterior es posible definir (Jacobiano):

$$J = \det \left( \frac{\partial \mathbb{S}}{\partial \mathbf{y}} \right) = \det \begin{pmatrix} \frac{\partial S_1}{\partial y_1} & \frac{\partial S_1}{\partial y_2} & \dots & \frac{\partial S_1}{\partial y_n} \\ \vdots & \vdots & & \vdots \\ \frac{\partial S_n}{\partial y_1} & \frac{\partial S_n}{\partial y_2} & \dots & \frac{\partial S_n}{\partial y_n} \end{pmatrix}$$

- La función de densidad conjunta del vector  $\mathbb{Y} = \mathbb{T}(\mathbb{X})$ , está dada por:

$$f_{\mathbb{Y}}(\mathbf{y}) = \begin{cases} f_{\mathbb{X}}(\mathbf{s})|J| & \text{si } \mathbf{s} \in \Theta \\ 0 & \text{en otro caso} \end{cases}.$$

Donde  $\Theta$  es el recorrido de la transformación  $\mathbb{T}$  y  $|\cdot|$  indica valor absoluto. Entencer lo anterior es más claro viendo un ejemplo.

4. [Ejemplo 6](#): Asume que se tiene un vector aleatorio  $\mathbb{X} = (X_1, X_2)$  con f.d. dada por:

$$f_{\mathbb{X}}(\mathbf{x}) = f_{X_1, X_2}(x_1, x_2) = 4x_1x_2I_{(0,1) \times (0,1)}(x_1, x_2). \quad (7)$$

Asume se desea la función de densidad de  $Y = X_1 + X_2$ , pero ésta transformación no es 1-a-1. Por lo anterior podemos seguir el siguiente **camino**:

- $\mathbb{Y} = (Y, Z) = (X_1 + X_2, X_1 - X_2)$
- De lo anterior:  $\mathbb{X} = (X_1, X_2) = \left(\frac{Y+Z}{2}, \frac{Y-Z}{2}\right)$ ,
- Es decir la transformación  $\mathbb{Y}$  es 1-a-1, y, los resultados presentados nos permiten llegar a  $f_{\mathbb{Y}}(\mathbf{y})$ .
- Luego hallaremos  $f_Y(y)$ , como una marginal.

El camino a seguir es hallar  $f_{\mathbb{Y}}(\mathbf{y})$ , paso-a-paso es como sigue:

- $y = T_1(\mathbf{x}) = x_1 + x_2 \in (0, 2)$  y  $z = T_2(\mathbf{x}) = x_1 - x_2 \in (-1, 1)$ .
- Observa  $z = x_1 - x_2 \leq x_1 \leq x_1 + x_2 = y$ .
- $S_1(\mathbf{y}) = \frac{y+z}{2}$  y  $S_2(\mathbf{y}) = \frac{y-z}{2}$ .
- De lo anterior

$$J = \det \begin{pmatrix} \frac{1}{2} & \frac{1}{2} \\ \frac{1}{2} & -\frac{1}{2} \end{pmatrix} = -\frac{1}{2}$$

- Hemos llegado:

$$\begin{aligned} f_{\mathbb{Y}}(\mathbf{y}) &= \begin{cases} f_{\mathbb{X}}(\mathbf{s}) |J| & \text{si } 0 < y < 2, -1 < z < 1, z \leq y \\ 0 & \text{en otro caso.} \end{cases} \\ &= \begin{cases} \frac{1}{2}(y+z)(y-z) & \text{si } 0 < y < 2, -1 < z < 1, z \leq y \\ 0 & \text{en otro caso.} \end{cases} \end{aligned}$$

5. **Ejemplo 7:** Se tiene un vector aleatorio  $\mathbb{X} = (X_1, X_2)$  con f.d. conocida  $f_{\mathbb{X}}(\mathbf{x})$ .

- Si se desea la función de densidad de  $Y = X_1 * X_2$ , el camino a seguir es definir  $Z = X_1$ , de donde se tiene  $\mathbb{Y} = (Y, Z)$  y  $\mathbb{X} = (Z, \frac{Y}{Z})$ .
- Si se desea la función de densidad de  $Y = \frac{X_1}{X_2}$ , el camino a seguir es definir  $Z = X_2$ , de donde se tiene  $\mathbb{Y} = (Y, Z)$  y  $\mathbb{X} = (YZ, Z)$ .

6. **Lectura:** Paradoja de Borel - Kolmorov. Pg 171, Degroot(1986)

Fin - Clase del día Miércoles Dic. 18